基于颜色直方图与预训练深度特征的“以图搜图”实现与对比分析

计算机视觉课程实验报告

摘 要：本文围绕基于内容的图像检索 (Content–Based Image Retrieval, CBIR) 任务，构建了包含 10 个语义类别的图像检索数据集（查询集 20 张、检索库 9,469 张），实现了统一的图像读取与预处理流程，并分别采用 **RGB 三通道归一化颜色直方图（48 维）**与 **ImageNet 预训练 ResNet–50 全局池化深度特征（2048 维）** 进行特征提取。在 L_2 特征归一化基础上，利用余弦相似度完成全库检索与 Top–5 结果排序可视化。实验表明，在大规模检索库干扰下，RGB 颜色直方图的 Top–1 准确率为 45.0%、Precision@5 为 35.0%，仅在大面积背景色调高度统一（如蓝天下的降落伞）时表现较好，而在复杂背景或灰度图像上极易产生异类误检；相比之下，预训练 ResNet–50 深度特征无需微调即可在全部 20 张查询图上达到 **100.0% 的 Top–1 准确率与 Precision@5**。报告最后深入剖析了两种特征所表达与忽略的视觉信息，并针对“找出同一件物品的不同图片”（实例级图像检索）给出了从算法改造到评价指标设计的完整方案。

1 任务背景与整体流程

“以图搜图”（即基于内容的图像检索，CBIR）是指在不依赖人工文本标签的前提下，直接根据查询图像自身的视觉内容，从图像库中找出视觉相似或语义同类图像的技术。由于原始图像像素矩阵维度极高（例如一张 500×375 的 RGB 图像包含 $562,500$ 个像素值），且像素值会随物体平移、缩放、视角变化而剧烈改变，直接逐像素比对既耗时又毫无鲁棒性。

因此，一个完整的以图搜图系统通常由四个核心环节构成：

1. **图像读取与预处理**：消除格式、色彩通道数、旋转方向与输入尺寸的差异；
2. **特征提取**：将高维原始图像映射为紧凑的一维数值特征向量 $\boldsymbol{x} \in \mathbb{R}^d$，使其尽可能保留核心视觉属性（如色彩分布或高层语义）；
3. **相似度计算与排序**：在特征空间中度量查询图特征 $\boldsymbol{q}$ 与检索库中每张图片特征 $\boldsymbol{g}_i$ 的相似程度，按得分从高到低排序；
4. **Top–K 结果可视化与评估**：展示排名前 K（本实验 $K = 5$）的检索结果，并从定量与定性两个维度检验检索效果。

2 数据集构建与图像预处理

2.1 数据集构建与划分

按照作业要求（至少 5 个类别，每类不少于 10 张图片，每类选出 2 张作为查询集，其余组成检索库），本实验基于公开图像数据集 Imagenette 构建了包含 **10 个语义类别** 的图像数据集。这 10 个类别涵盖了动物（英国史宾格犬、丁鲷）、交通工具与工程机械（垃圾车、加油泵、油锯）、建筑与户外场景（教堂、降落伞）以及日常与文体物品（圆号、磁带播放机、高尔夫球），类别多样性丰富。

为严格遵循“每类选出 2 张图片作为查询集”的要求，程序从每个类别的查询子目录中按顺序固定抽取 2 张图片，组成共 **20 张图片的查询集（Query Set）**；同时保留检索库目录中的全部 **9,469 张图片**

组成检索库（Gallery Set），查询集与检索库严格无交集。相比仅使用数十张图片的小型检索库，在近万张图像的检索库中寻找 Top-5 同类图片存在大量背景或色调相近的干扰项，更能真实检验不同特征提取方法的判别能力。各语义类别的具体数量分布如 表 1 所示，10 个类别的代表性样本见 图 1。

类别目录名称	中文语义含义	所属大类	查询集数量	检索库数量
English springer	英国史宾格犬	动物	2	955
tench	丁鲷（淡水鱼）	动物	2	963
French horn	圆号（铜管乐器）	乐器 / 日常物品	2	956
cassette player	磁带播放机	电子 / 日常物品	2	993
golf ball	高尔夫球	文体用品	2	951
chain saw	油锯（伐木电锯）	工具器械	2	858
garbage truck	垃圾清运车	交通工具	2	961
gas pump	加油站加油泵	交通设施	2	931
church	教堂建筑	建筑场景	2	941
parachute	高空降落伞	户外运动场景	2	960
合计（共 10 类）	—	—	**20**	**9,469**

表 1　实验数据集的类别构成与查询集 / 检索库数量统计（远超题目基准要求）



图 1　数据集中 10 个语义类别的代表性样本图像及其原始分辨率

2.2 图像读取与预处理

真实场景中的图像文件往往存在单通道灰度图（如老照片或雾天教堂）、四通道 RGBA 透明图、带有 EXIF 旋转标记的手机拍摄照片以及长宽比各异的分辨率。为此，程序在读取任何查询图与检索库图片时，首先执行统一的基础预处理，随后针对两种特征方法的数学特性执行各自的专用预处理：

1. **基础读取与通道对齐**：使用 Pillow 读取图像后，首先调用 `ImageOps.exif_transpose` 校正拍摄方向，随后统一调用 `.convert("RGB")` 转换为标准的三通道 8 位无符号整型数组（像素值范围 $[0, 255]$），保证单通道灰度图或 RGBA 图像不会引发维度不一致。
2. **颜色直方图分支的预处理**：颜色直方图关注整幅画面的色彩比例。若强行裁剪图像会丢失边缘区域色彩，因此保留原始全图，在统计频数后通过除以图像总像素数 $H \times W$ 将频数转化为概率分布，从数学上自然消除不同图片分辨率大小带来的计数差异。
3. **ResNet–50 深度特征分支的预处理**：严格对齐模型在 ImageNet–1K 预训练时的输入变换流程（`ResNet50_Weights.IMAGENET1K_V2.transforms()`）：
   - 将图像短边双线性插值缩放（Resize）至 232 像素，保持原始长宽比不变；
   - 执行 224×224 的中心裁剪（CenterCrop），并将像素值缩放至浮点区间 $[0.0, 1.0]$；
   - 按通道减去 ImageNet 均值 $\mu = [0.485, 0.456, 0.406]$ 并除以标准差 $\sigma = [0.229, 0.224, 0.225]$，使输入张量的数值分布与预训练卷积核所期望的输入分布完全匹配。

3 特征提取与相似度计算方法

3.1 方法一：RGB 颜色直方图特征

RGB 颜色直方图通过统计 R（红）、G（绿）、B（蓝）三个通道在各个亮度区间内的像素占比来刻画图像的色彩分布。设输入 RGB 图像尺寸为 $H \times W$，将每个通道的像素取值范围 $[0, 256)$ 均匀划分为 $B = 16$ 个区间（bin），第 b 个区间（$b = 0, 1, ..., B-1$）覆盖的灰度值范围为 $[16b, 16(b+1))$。

对于通道 $c \in \{R, G, B\}$，首先统计落入各区间的像素数量并除以总像素数完成 **单通道概率归一化（L_1 归一化）**：

$$h_c(b) = \frac{1}{H \cdot W} \sum_{i=1}^{H} \sum_{j=1}^{W} \mathbb{I}(16b \le I_c(i,j) < 16(b+1)), \quad \sum_{b=0}^{B-1} h_c(b) = 1$$

随后，将三个通道的 16 维归一化直方图首尾拼接，构成 $3 \times 16 = 48$ 维的联合颜色特征向量 $\boldsymbol{h} = [\boldsymbol{h}_R; \boldsymbol{h}_G; \boldsymbol{h}_B] \in \mathbb{R}^{48}$。最后对其进行 $\boldsymbol{L_2}$ **范数归一化**，得到单位长度特征向量：

$$\hat{\boldsymbol{h}} = \frac{\boldsymbol{h}}{\|\boldsymbol{h}\|_2} = \frac{\boldsymbol{h}}{\sqrt{\sum_{k=1}^{48} h_k^2}}$$

3.2 方法二：基于预训练 ResNet–50 的深度特征

卷积神经网络（CNN）通过堆叠卷积层、非线性激活与残差连接，能够从原始像素中逐层抽象出边缘、纹理、局部部件乃至整体语义。本实验选用在 ImageNet–1K 数据集上预训练的 **ResNet–50**（权重版本 `IMAGENET1K_V2`）作为特征提取骨干，无需进行任何重新训练或参数微调。

标准 ResNet–50 的最末端是一个将 2048 维特征映射为 1000 个类别对数概率的全连接分类层（`fc`）。在以图搜图任务中，我们希望获取通用的视觉语义表征而非特定分类概率，因此程序**直接截去最后一层全连接层**，保留从输入卷积到倒数第二层 **全局平均池化层（Global Average Pooling, GAP）** 的全部网络结构。

当预处理后的图像张量 $\boldsymbol{X} \in \mathbb{R}^{1 \times 3 \times 224 \times 224}$ 输入网络后（在 `torch.inference_mode()` 与 `model.eval()` 模式下前向推理），最后一个残差阶段输出形状为 $2048 \times 7 \times 7$ 的高层特征图，经全局平均池化后浓缩为一维向量 $\boldsymbol{f} \in \mathbb{R}^{2048}$。同样对其执行 L_2 归一化得到单位特征向量 $\hat{\boldsymbol{f}} = \frac{\boldsymbol{f}}{\|\boldsymbol{f}\|_2}$。单张查询图在两种方法下的特征提取结果对比如 图 2 所示。

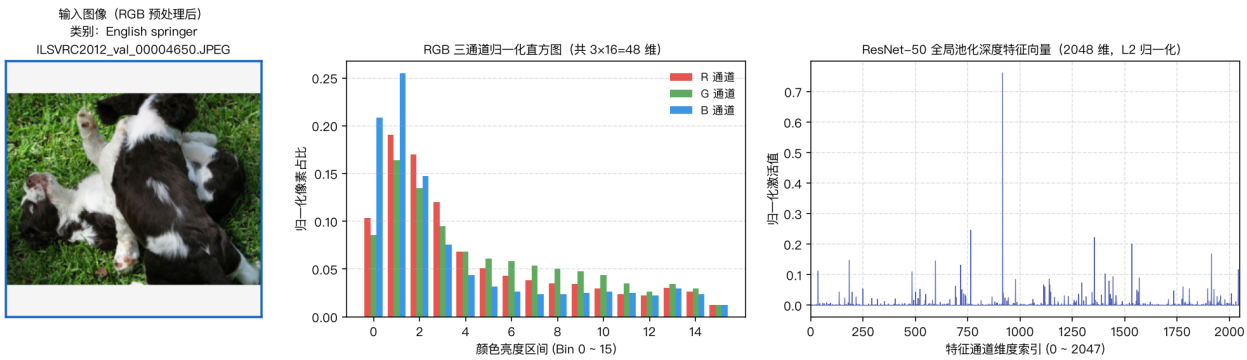


图 2　单张查询图（English springer）的预处理结果、48 维 RGB 三通道归一化直方图与 2048 维 ResNet-50 深度特征激活分布

3.3 相似度计算与排序方式

由于两种特征提取器输出的向量 $\hat{\boldsymbol{q}}$（查询图）与 $\hat{\boldsymbol{g}}_i$（检索库第 i 张图）均已完成 L_2 单位化（即 $\|\hat{\boldsymbol{q}}\|_2 = \|\hat{\boldsymbol{g}}_i\|_2 = 1$），本实验统一采用 **余弦相似度（Cosine Similarity）** 度量特征间的相似程度，其计算可直接简化为向量点积：

$$\mathrm{sim}(\hat{\boldsymbol{q}}, \hat{\boldsymbol{g}}_i) = \frac{\hat{\boldsymbol{q}}^\top \hat{\boldsymbol{g}}_i}{\|\hat{\boldsymbol{q}}\|_2 \|\hat{\boldsymbol{g}}_i\|_2} = \hat{\boldsymbol{q}}^\top \hat{\boldsymbol{g}}_i \in [-1, 1]$$

值得指出的是，在单位超球面上，余弦相似度与 **欧氏距离（Euclidean Distance）** 存在严格的单调递减对应关系：

$$d_{L_2}(\hat{\boldsymbol{q}}, \hat{\boldsymbol{g}}_i) = \|\hat{\boldsymbol{q}} - \hat{\boldsymbol{g}}_i\|_2 = \sqrt{\|\hat{\boldsymbol{q}}\|_2^2 + \|\hat{\boldsymbol{g}}_i\|_2^2 - 2\hat{\boldsymbol{q}}^\top \hat{\boldsymbol{g}}_i} = \sqrt{2 - 2\ \mathrm{sim}(\hat{\boldsymbol{q}}, \hat{\boldsymbol{g}}_i)}$$

这意味着按余弦相似度从大到小排序，与按欧氏距离从小到大排序的检索结果完全等价，且矩阵乘法 $G\hat{q}$ 可在毫秒级内完成对 9,469 张检索库图片的并行打分。

此外，针对颜色直方图的概率分布属性，我们还在代码库中实现了街区距离（L_1 Distance）与直方图相交度（Histogram Intersection，$\sum_k \min(p_k, q_k)$）进行横向对比。如 表 2 所示，在 20 张查询图上，余弦相似度 / 欧氏距离在颜色直方图上取得了略优于 L_1 距离和直方图相交度的检索准确率，因此主实验统一使用余弦相似度并取排名前 5（Top-5）的图片返回。

度量方式	计算公式（对已归一化特征）	Top-1 准确率	Precision@5	mAP@5
余弦相似度 (cosine)	$\hat{\boldsymbol{q}}^\top \hat{\boldsymbol{g}}$（越大越相似）	**45.0%**	**35.0%**	**49.6%**
欧氏距离 (euclidean)	$\|\hat{\boldsymbol{q}} - \hat{\boldsymbol{g}}\|_2$（与余弦严格等价）	**45.0%**	**35.0%**	**49.6%**
街区距离 (l1)	$\sum_k \|\hat{q}_k - \hat{g}_k\|$（越小越相似）	40.0%	33.0%	47.3%
直方图相交 (intersection)	$\sum_k \min(p_k, g_k)$（越大越相似）	40.0%	32.0%	47.5%

表 2　RGB 颜色直方图特征在不同相似度 / 距离度量方式下的检索性能对比

4 检索结果可视化与实验对比

4.1 整体定量评测结果

为客观衡量两种特征提取方法在全部 20 张查询图上的表现，我们统计了四项核心指标：

- **Top-1 准确率**：排名第 1 的检索结果与查询图属于同一类别的查询图比例；
- **Hit@5（前 5 命中率）**：排名前 5 的结果中至少包含 1 张同类图片的查询图比例；
- **Precision@5（前 5 查准率）**：排名前 5 的结果中同类图片所占的平均比例；
- **mAP@5（前 5 平均精度均值）**：综合考虑同类图片命中数量与排名先后顺序的指标（同类图片排位越靠前得分越高）。

两种特征方法的整体评测结果与按类别细分的 Precision@5 对比如 表 3 和 图 3 所示。

特征提取方法	特征维度	Top-1 准确率	Hit@5	Precision@5	mAP@5
RGB 颜色直方图	48 维	45.0% (9/20)	85.0% (17/20)	35.0% (35/100)	49.6%
ResNet-50 深度特征	**2048 维**	**100.0% (20/20)**	**100.0% (20/20)**	**100.0% (100/100)**	**100.0%**

表 3　20 张查询图在 9,469 张检索库上的整体检索性能对比

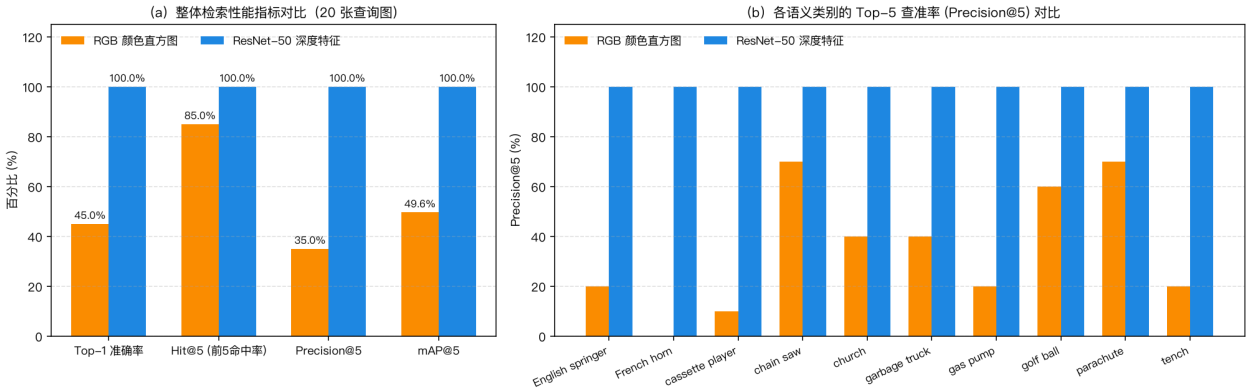


图 3　RGB 颜色直方图与 ResNet-50 深度特征的（a）整体指标对比与（b）各语义类别 Precision@5 对比

从定量结果可以清晰看出：

1. **ResNet-50 深度特征展现压倒性优势**：在包含 9,469 张图片的检索库中，20 张查询图返回的共 100 张 Top-5 结果全部命中各自对应的正确类别，各项指标均达到 **100.0%**。
2. **RGB 颜色直方图类别分化严重**：整体 Precision@5 仅为 **35.0%**。仅在背景色彩极度鲜明且单一的类别（如天空背景的 `parachute` 达到 70.0%、绿茵草地背景的 `golf ball` 达到 60.0%、森林背景的 `chain saw` 达到 70.0%）表现尚可；而在物体自身颜色多变或背景复杂的类别（如 `French horn` 为 0.0%、`cassette player` 为 10.0%、`English springer`、`gas pump` 和 `tench` 均为 20.0%）上几乎失效。

4.2 典型检索结果可视化与案例剖析

实验程序对全部 20 张查询图均生成了符合要求的可视化结果图（完整 40 张检索图已保存在 `results/notebook/` 及实验 Notebook 中）。每张可视化图左侧为蓝色边框标注的查询图片及其类别，右侧依次展示排名前 5 的检索结果、排名序号、类别、余弦相似度以及是否同类的状态标记（绿色边框代表 `[同类]` 命中，红色边框代表 `[异类]` 误检）。以下选取 4 个极具代表性的案例进行对比分析：

4.2.1 案例一：复杂自然背景干扰（英国史宾格犬 `English springer`）

如 图 4 所示，查询图是一只在绿色草地上打滚的棕白相间史宾格犬。

- **RGB 颜色直方图（上排，P@5 = 1/5）**：直方图仅记录了“画面中有一定比例的绿色、棕色和白色”，却完全不知道这些颜色构成了什么形状。结果其 Top–1 检索出了一颗落入枯枝绿叶间的脏白色高尔夫球（余弦相似度高达 0.9797），Top–3 是一辆停在绿色树林前的白色垃圾车（0.9768），Top–4 是在树枝间作业的伐木工人（0.9751）。这三张误检图与查询图在语义上毫无关联，仅仅因为“绿植 + 棕白块”的全局色调比例极其接近而排到了最前面。
- **ResNet–50 深度特征（下排，P@5 = 5/5）**：深度特征准确捕捉了史宾格犬垂耳、毛发斑块与躯干的视觉形态，无论是吃食、站立、涉水还是坐姿，前 5 名全部精准找回同类犬只。



图 4　案例一（`English springer`）：颜色直方图被绿草与棕白配色误导，而 ResNet–50 全部命中

4.2.2 案例二：光照与色彩缺失（雾天灰调教堂 `church`）

如 图 5 所示，查询图是一张在浓雾天气下拍摄的近乎单色（黑白灰调）的哥特式尖顶教堂照片，R、G、B 三通道的像素直方图几乎完全重叠。

- **RGB 颜色直方图（上排，P@5 = 1/5）**：由于缺乏鲜明的色彩线索，颜色直方图退化为单纯的明暗对比度匹配，搜出了树林阴影下的油锯（Top–1、Top–4）和暗色渔网中的丁鲷（Top–2、Top–5）。
- **ResNet–50 深度特征（下排，P@5 = 5/5）**：深度网络对色彩缺失表现出极强的鲁棒性，它依靠高耸的钟楼尖塔、拱形立面等几何与纹理特征，跨越夜景暖光（Top–1、Top–2）与白天晴空（Top–3 Top–5）的巨大色彩差异，稳定找回 5 张哥特式教堂图像。



图 5　案例二（church）：灰度查询图下颜色直方图严重误检，ResNet-50 依靠建筑结构特征跨光照命中

4.2.3 案例三：小目标前景被背景淹没（圆号 French horn）

如 图 6 所示，查询图中乐手手持圆号，金黄色的圆号管体仅占画面中心一角，而周围大面积区域为深色服装与室内暗背景。颜色直方图被大面积暗色背景主导，Top-5 全部误检为同样具有暗色背景的油锯、教堂和垃圾车（P@5 = 0/5）；而 ResNet-50 对螺旋盘绕的金属铜管与号口结构产生了强激活响应，实现了 5/5 命中。

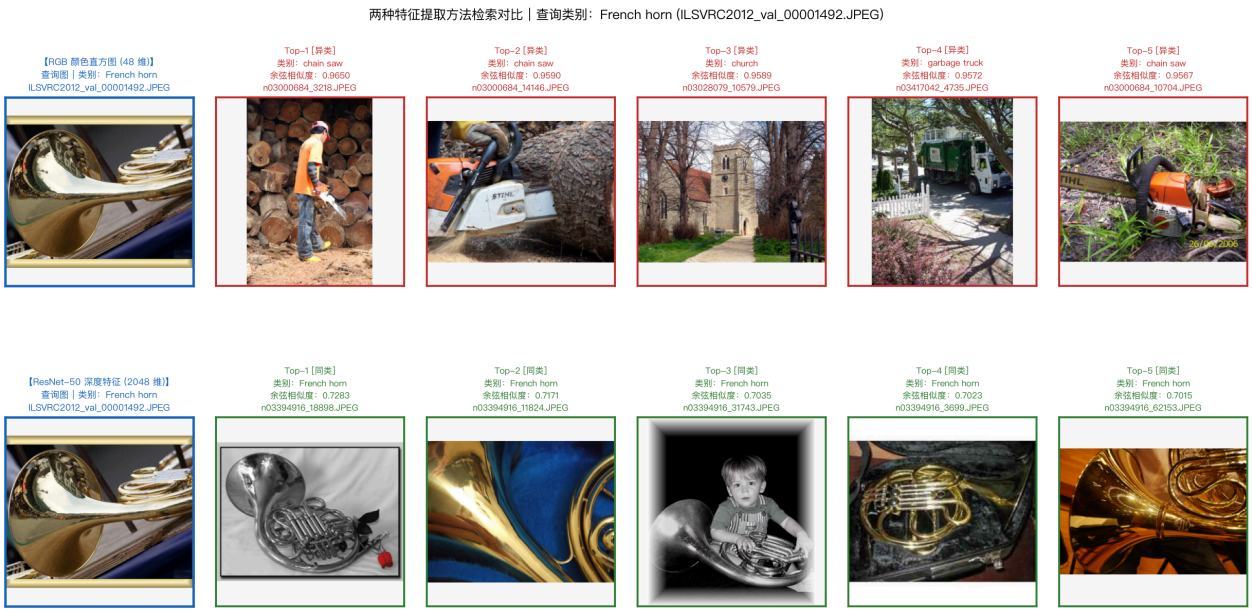


图 6　案例三（French horn）：局部前景在颜色直方图中被大面积暗背景淹没（0/5），ResNet-50 准确识别（5/5）

4.2.4 案例四：大面积纯色背景下的“表面成功”（降落伞 parachute）

如 图 7 所示，在该查询图上，RGB 颜色直方图与 ResNet-50 均取得了 P@5 = 5/5 的成绩。但仔细审视颜色直方图检索出的 **Top-3 图片**（n03888257_11587.JPEG）可以发现一个非常有趣的现象：该图中只有一名在蓝天中自由落体的人，**画面里根本没有展开的降落伞**！这有力地证明了：颜色直方图之所以在 parachute 类别上准确率高，并不是因为它认出了“降落伞”，而是因为该类别的图片大多以大面

积蔚蓝天空为背景，直方图实际上是在执行“找蓝天”的任务；而 ResNet-50 检索出的前 5 名则全部包含清晰的条纹伞盖与伞绳结构。

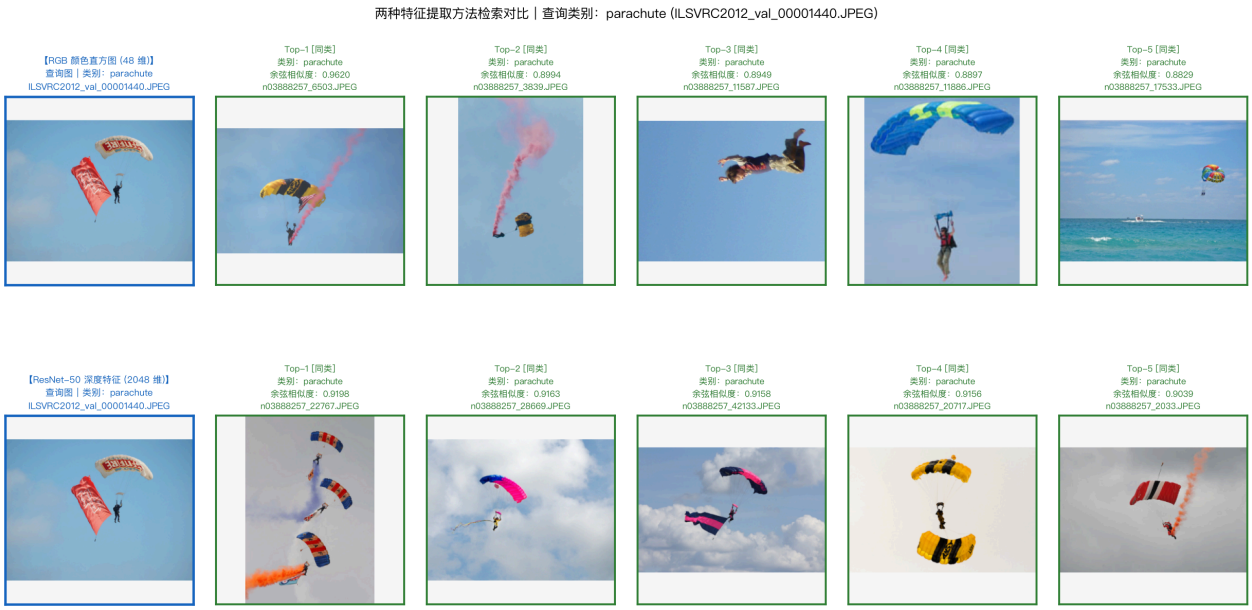


图 7　案例四（parachute）：两种方法均命中 5/5，但颜色直方图 Top-3 仅匹配了蓝天背景而无降落伞伞盖

5 分析与讨论

5.1 问题 a)：两种特征分别描述了哪些信息？哪些信息可能被忽略？

结合上述实验现象与特征构造方法，两种特征所描述和忽略的信息总结如 表 4 所示，具体分析如下：

特征类型	主要描述的信息	被忽略或丢失的关键信息
RGB 颜色直方图	1. 整幅图像的**全局色彩统计分布**（R/G/B 各亮度区间的像素占比）； 2. 图像的整体明暗基调与主色调构成。	1. **空间位置与几何排布**（像素打散统计，前景与背景完全混同）； 2. **形状轮廓、边缘结构与局部纹理**； 3. **高层物体语义概念**； 4. 光照恒常性（对色温、曝光、滤镜变化极其敏感）。
ResNet-50 深度特征	1. 从低层边缘纹理、中层部件结构到高层的**物体语义表征**； 2. 对光照、背景杂波、视角形变鲁棒的**类别级判别特征**。	1. **精确的像素级空间坐标与几何构图关系**（因多次下采样与全局平均池化 GAP 而被压缩）； 2. **细粒度的个体身份差异**（分类预训练倾向于抹平同类不同个体间的微小细节）； 3. **绝对色彩比例与低层精细外观**。

表 4　RGB 颜色直方图与预训练深度特征所描述及忽略的信息对比

1. **RGB 颜色直方图特征**：
   - **描述的信息**：它本质上是对整幅图像所有像素进行“无位置统计”的一阶色彩分布特征，回答的是“画面里红、绿、蓝各亮度的像素分别占多大比例”。由于只计数不看位置，它天然具备**图像平移不变性、旋转不变性**，且在除以总像素数后具备**尺度缩放不变性**，计算速度极快。

- **忽略的信息**：
  - **空间结构与位置信息完全丢失**：即使把一张图片的所有像素随机打乱成一张毫无意义的雪花噪点图，其 RGB 颜色直方图也与原图分毫不差。因此它无法区分“前景主体”与“背景环境”，一旦前景较小（如圆号），特征就会被大面积背景色完全统治。
  - **形状、纹理与高层语义缺失**：它不知道像素之间是否构成犬耳、车轮或教堂尖塔，导致“同色调异物”（如绿草地上的狗与绿树林前的垃圾车）获得极高相似度。
  - **忽略光照与色温变化的影响**：同一件物品在阳光直射、阴影、暖黄灯光或黑白滤镜下，RGB 像素值会发生整体漂移（“同物不同色”），直方图相似度会断崖式下降。

2. **基于预训练神经网络（ResNet-50）的深度特征**：
   - **描述的信息**：通过深层卷积网络的层次化感受野，浅层网络提取边缘、角点与局部色彩纹理，中层网络组合出局部部件（如犬鼻、车窗、拱门、伞绳），深层网络则将这些部件整合为**高维语义概念**。因此它主要描述“图像中包含什么类别的物体及其核心结构属性”。
   - **忽略的信息**：
     - **精确的几何空间位置与局部构图**：ResNet-50 末尾的全局平均池化层（GAP）将 7×7 的空间特征图直接求均值压缩为 1×1，加上中心裁剪（CenterCrop）可能切掉图像边缘，物体在画面中的精确坐标、相对几何方位和精细构图被大幅弱化。
     - **同类不同个体之间的细粒度身份特征（Instance-level Details）**：因为该模型是在 ImageNet 上用交叉熵损失做“类别分类”训练的，训练目标迫使网络放大“类间差异”、压制“类内差异”（即不管是一只棕色史宾格犬还是黑白史宾格犬，网络都努力让它们输出相近的向量）。因此，同一类别下不同个体之间的独特纹理、微小划痕、编号或特定图案往往被网络当成“类内噪声”而忽略。
     - **精确的全局颜色分布**：为了在不同光照和染色下都能正确分类物体，深度网络在深层会有意削弱对绝对色彩的敏感度。

5.2 问题 b)：若将任务改为“找出同一件物品的不同图片”，检索方法需做哪些调整？如何设计评价标准？

将任务从当前的“找出同一类别的图片（Category-level Retrieval）”改为“找出同一件具体物品在不同角度、光照或场景下的图片（实例级检索，Instance-level Retrieval）”，任务难度和核心矛盾发生了根本转变：**之前需要容忍同类不同个体间的差异，现在则必须敏锐区分同款或同类物品之间的细微个体差异，同时抵抗跨场景背景和视角变化。**

5.2.1 检索方法的调整方案

1. **引入前景主体检测与分割（消除背景干扰）**：同一件物品被拿到不同房间或户外拍摄时，背景会发生彻底改变。如果在整张图上提取特征，背景变化会严重拉低相似度。因此应在预处理阶段引入通用目标检测器（如 YOLO、Grounding DINO）或显著性分割模型（如 SAM），自动框选或抠出画面中的主体物品区域（ROI），仅针对裁剪后的物品主体提取特征。

2. **特征提取改进：融合多区域局部特征与空间几何验证（Spatial Verification）**：
   - **改进池化方式**：将简单的全局平均池化（GAP）替换为对显著局部响应更敏感的 **GeM（Generalized Mean Pooling）**，或采用 **R-MAC（Regional Maximum Activation of Convolutions）** 在特征图的多个滑动窗口尺度上提取局部区域特征并聚合。
   - **局部关键点匹配与几何重排序（Re-ranking）**：要确认两张图是不是“同一件物品”（例如同一个带有特定图案的磁带机或同一座特定教堂），最可靠的依据是局部关键点在几何上能否严丝合缝地对齐。可在全局特征粗排选出 Top-50 候选图后，提取局部特征点（如 SIFT，或深度学习局部特

征 SuperPoint + LightGlue），利用 **RANSAC 算法估计单应性变换矩阵（Homography）或基础矩阵**，统计满足空间几何一致性的内点数量（Inliers Count）进行重排序。

3. **模型训练目标调整：采用实例级度量学习（Metric Learning）或自监督骨干**：
   - 预训练分类网络倾向于把“所有圆号”聚成一团。应改用实例检索数据集（如地面地标 Google Landmarks、商品库 Stanford Online Products），使用 **三元组损失（Triplet Loss）**、**对比损失（Contrastive Loss）** 或 **ArcFace 损失** 对网络进行度量学习微调：明确将“同一件物品的不同拍摄图”作为正样本对拉近，而将“同一类别但不同件的物品”作为难负样本（Hard Negatives）推远。
   - 若不进行微调，也可将骨干网络替换为基于自监督对比学习预训练的视觉大模型（如 **DINOv2**），由于其未经类别标签的强行坍缩，天然保留了极佳的细粒度局部纹理与实例区分度。
4. **多模态特征融合（结合局部颜色与纹理特征）**： 对于“同款不同色”的两件商品，纯语义深度特征可能给出极高相似度。此时可在前景分割区域内，将深度实例特征与前景局部颜色直方图（建议使用对光照更解耦的 HSV 或 Lab 颜色空间）进行加权拼接，兼顾结构一致性与色彩一致性。

5.2.2 评价标准的设计

1. **测试数据集与真值标注（Ground Truth）构建**：
   - 不再按粗粒度语义类别标注，而是为每一件独立实体物品分配唯一的 **实例编号（Instance ID）**。
   - 每个实例应采集不同拍摄角度（正面、侧面、俯视）、不同光照条件、不同背景以及部分遮挡下的多张图片（假设对于查询图 q，检索库中共有 M_q 张属于同一件物品的正样本图片）。
   - 检索库中应当特意混入大量**同类别但非同一件物品的干扰项（Hard Distractors）**，以检验算法是否只是在做粗粒度分类。
2. **核心定量评价指标**：
   - **mAP（Mean Average Precision，平均精度均值）**： 这是实例级检索最核心的黄金指标。因为同一件物品在检索库中往往不止 1 张图（共 M_q 张），我们不仅希望把这 M_q 张图全部找出来，还希望它们都排在异物图片的前面。对单张查询图 q，其平均精度 $\mathrm{AP}(q)$ 定义为每个正样本被检索出位置处的查准率均值，再对所有查询图求平均得到 mAP：

$$\mathrm{AP}(q) = \frac{1}{M_q} \sum_{k=1}^{N} P_q(k) \cdot \mathrm{rel}_q(k), \quad \mathrm{mAP} = \frac{1}{|Q|} \sum_{q \in Q} \mathrm{AP}(q)$$

     其中 $\mathrm{rel}_q(k) \in \{0, 1\}$ 表示排名第 k 的图片是否与 q 为同一件物品，$P_q(k)$ 为前 k 个结果中同一件物品的占比。
   - **Recall@K（前 K 召回率，如 R@1、R@5、R@10）**： 衡量在返回的前 K 张结果中，找回了检索库中该物品全部 M_q 张正样本图片的比例（即 $\mathrm{Recall@}K = \frac{1}{M_q} \sum_{k=1}^{K} \mathrm{rel}_q(k)$），或者衡量前 K 名中至少出现 1 张该物品图片的查询占比（Hit Rate@K）。
   - **Precision–Recall（PR）曲线**： 通过改变返回结果截断阈值，绘制查准率（Precision）随查全率（Recall）变化的曲线，曲线下面积越大说明检索系统在查准与查全之间的平衡越好。
   - **开集拒识指标（针对库中可能不存在该物品的场景）**： 在实际应用中，用户上传的物品可能在检索库中根本没有同件图片。此时需设定相似度阈值 τ，当最高相似度低于 τ 时判定为“库中无此物品”，并通过 **误识率（FAR，将不同物品误判为同一件）**、**拒识率（FRR，将同一件物品漏判）** 以及两者的相等错误率（**EER**）来综合评估系统的实用可靠性。